FACULTAD DE CIENCIAS ECONÓMICAS Y EMPRESARIALES

PROGRAMA ACADÉMICO DE ECONOMÍA

SÍLABO — 2026-II[1]

DATOS INFORMATIVOS

Asignatura	TÓPICOS DE ECONOMÍA DE LA EMPRESA
Nombre real del curso	Machine Learning: Econometría para *Big Data* usando Python
Sigla	E2TEE9
Sección	A
N° de créditos	3.0
Semestre	2026-II
Profesor	Mgtr. Martin Anthony Vargas Alvines
Modalidad	Virtual
Día y hora de clase	Martes de 7 p.m. a 10 p.m. (hora de Piura, UTC−5)
Enlace de Zoom	Enlace para acceder al salón virtual vía Zoom
Plataforma del curso	CANVAS UDEP (módulos por sesión: diapositivas, laboratorio, grabación)
Correo del profesor	martin.vargas.a@udep.edu.pe[2]
Horario de atención[3]	Viernes de 3:00 p.m. a 4:00 p.m. (hora de Piura, UTC−5), virtual. Enlace Zoom.

REQUISITOS PREVIOS

Se recomienda que el/la estudiante haya aprobado un curso introductorio de Econometría (Econometría I o equivalente) y cuente con nociones básicas de estadística y álgebra lineal. No se requiere experiencia previa en programación: Python se enseña desde cero a lo largo del curso mediante los laboratorios.

No obstante, cabe mencionar que, dado el nombre y registro del curso, el curso requerido (en papel) es Teoría de la Organización Industrial.

[1] Última actualización: 18 de agosto de 2026.
[2] Note el "*.a*", antes del arroba.
[3] Previo aviso.

SUMILLA

Aviso: el nombre oficial de este curso en el sistema académico es "Tópicos de Economía de la Empresa" por motivos administrativos de la malla curricular, pero el nombre que mejor describe su contenido real es "Machine Learning: Econometría para Big Data usando Python". A lo largo de este sílabo y del curso se hará referencia a este segundo nombre.

Es un curso de carácter teórico-práctico que corresponde al área de Formación General. Este curso brinda una introducción al Aprendizaje Automático, más conocido como Machine Learning (ML). Primero, se estudiarán los fundamentos econométricos detrás del ML; luego, se estudiarán métodos de ML para el análisis de macrodatos, más conocidos como Big Data (BD). Este curso presenta una estructura de Provisión de herramientas → Estudio de metodologías → Aplicaciones: se procurará aplicar todo lo aprendido a variables económicas de la realidad. Para el dictado de este curso se utiliza el software Python a través de la interfaz Jupyter. Este curso incluye laboratorios en los que se enseñará a utilizar Python con un enfoque económico-econométrico desde cero. Además, se discutirá la adopción de la inteligencia artificial (LLM generativos) como herramienta complementaria para los economistas.

FUNDAMENTACIÓN

Este curso provee a los estudiantes conocimientos sobre ML y análisis de BD, temas cada día más relevantes para los economistas dada la creciente disponibilidad de grandes bases de datos, el acceso a nueva tecnología para procesar datos, la inteligencia artificial (LLM generativos) y la necesidad de profesionales con las capacidades no solo de analizarlos (data science) sino también de interpretarlos y utilizarlos para entender las dinámicas de las variables económicas: buscar causalidades, entenderlas y/o realizar predicciones. Además, este curso satisface la necesidad de conocer al menos un lenguaje de programación a un nivel más que básico, desde un enfoque económico.

OBJETIVOS DE APRENDIZAJE

Objetivos generales del curso

- Expandir las perspectivas sobre la econometría que el alumno ha aprendido hasta el momento.
- Presentar el análisis estadístico-econométrico bayesiano, cada día más utilizado en la práctica profesional.
- Lograr que los alumnos dominen Python a través de la interfaz de Jupyter al finalizar el curso.
- Dotar a los alumnos de estrategias para un análisis econométrico correcto y eficiente de *Big Data* usando *Machine Learning*.

Actividad complementaria

Además de los objetivos de aprendizaje, el curso incluye espacios con perfiles de economistas UDEP (exalumnos) desempeñándose en distintas ramas de la economía, con el fin de mostrar posibles trayectorias profesionales (ver sección "Adicionales").

Resultados de aprendizaje por bloque temático

Al finalizar cada bloque, el/la estudiante debería ser capaz de lo siguiente:

Bloque temático	Resultado de aprendizaje esperado para alumnos UDEP
Algoritmos, aprendizaje e inferencia estadística; filosofías econométricas	Distinguir los enfoques frecuentista, bayesiano y fisheriano, y explicar cuándo aplicar cada uno.
Análisis econométrico bayesiano	Calcular e interpretar priors y posteriors en problemas econométricos sencillos usando Python.
Big data, IA y Economía	Identificar oportunidades y limitaciones del uso de Big Data e IA generativa en el análisis económico.
Aprendizaje no supervisado (PCA, *Clustering*, KNN)	Implementar y evaluar en Python técnicas de reducción de dimensionalidad y agrupamiento sobre datos económicos reales.
Regresor James-Stein, *Sparse Modeling*, Ridge/Lasso	Aplicar métodos de regularización y explicar el *trade-off* sesgo-varianza que resuelven.
Logit, árboles de regresión	Construir e interpretar modelos de clasificación y árboles de decisión aplicados a variables económicas.
Jackknife, Bootstrap, Validación cruzada	Cuantificar la incertidumbre de un estimador mediante remuestreo y seleccionar modelos por validación cruzada.
Random forest, poda, *boosting* y *bagging*	Construir modelos de ensamble (*ensemble*) en Python y justificar su uso frente a un modelo simple.

METODOLOGÍA Y HERRAMIENTAS DE TRABAJO

Estructura de la clase

- La clase dura 3 horas lectivas: usualmente 2 horas "teóricas" y 1 hora práctica (laboratorio).
- Cada bloque de 50 minutos es seguido de una pausa de 10 minutos (se repite 3 veces).
- Entorno de trabajo: **Python** a través de Jupyter, instalado vía Anaconda (ver guía de instalación "Lab 1.1 – Descarga de Anaconda y Jupyter" publicada en Canvas).

Requisitos técnicos

Dado que el curso es enteramente virtual y que la cámara encendida es condición tanto del punto por asistencia perfecta como de la validez de las evaluaciones, cada estudiante requiere: una computadora capaz de ejecutar Anaconda y Jupyter (se recomiendan al menos 8 GB de RAM y 10 GB de espacio libre), cámara web funcional y una conexión a internet estable. Quien tenga una limitación técnica que le impida cumplir con esto debe comunicarlo al profesor durante la primera semana de clases.

Organización del material en Canvas

- Cada sesión tiene un módulo en Canvas con 3 partes: (i) diapositivas de la sesión, (ii) laboratorio y (iii) enlace a un vídeo resumen de la clase.
- El *beamer* de cada clase se publica poco antes de la misma; las lecturas y códigos (cuando aplique) se publican la noche del jueves previo a la clase.
- La sección de Anuncios en Canvas contiene avisos importantes: se pide revisarla con frecuencia.

- La información de diapositivas y clase es suficiente para fines de evaluación: no es necesario recurrir a lectura adicional de los libros de la bibliografía para aprobar el curso, aunque se recomienda para profundizar.
- No todo lo enseñado en clase queda registrado en diapositivas o código: es responsabilidad de cada estudiante tomar notas de manera síncrona o asíncrona.
- Todas las sesiones se graban y se publican para consulta de los estudiantes del curso. Los enlaces a las grabaciones se centralizan en la siguiente hoja de cálculo de Google Sheets, además de estar en el módulo "Enlaces Zoom" en Canvas.
- Las grabaciones son de uso exclusivo de los estudiantes matriculados; no está permitido redistribuirlas fuera del curso. Al participar en las sesiones, los estudiantes consienten en aparecer en dichas grabaciones.

Estrategias metodológicas

- Aprendizaje práctico en laboratorio: cada tema se trabaja mediante ejercicios aplicados directamente en Python.
- Creación de código en tiempo real durante la clase.
- Participación en clase y controles de conocimiento adquirido.
- Ejercicios guiados y autónomos con datos económicos reales o simulados.

CONTENIDOS Y CRONOGRAMA

El profesor se reserva el derecho de cambiar el contenido del material del curso si percibe la necesidad de hacerlo debido al aplazamiento de clases causado por feriados o enfermedad del instructor, o debido al ritmo del curso. Cualquier cambio será notificado mediante un anuncio en Canvas y se proporcionará un horario de curso actualizado.

A continuación, un calendario con fechas tentativas. La línea de EXAMEN PARCIAL marca el corte de la evaluación acumulativa. En caso de que haya lecturas previas requeridas, estas serán publicadas cinco días antes de la clase programada. Las lecturas sugeridas por capítulo son una guía de referencia; no son obligatorias para la evaluación (ver "Metodología y herramientas de trabajo").

N°	Fecha	Temas (teoría)	Laboratorio (práctica)	Evaluación asociada	Lectura sugerida
1	18-Ago	-Presentación del curso, sílabo y evaluaciones -Algoritmos, aprendizaje estadístico e inferencia estadística	Laboratorio 1.1: Conociendo Python	—	ISLR* cap. 2
2	25-Ago	-¿Diferentes filosofías econométricas? Frecuentista, Bayesiana y Fisheriana	Laboratorio 2.1: NumPy (paquete matemático)	—	Spanos** cap. 1–2
3	1-Sep	-Análisis econométrico bayesiano: priors y posteriors	Laboratorio 2.2: Matplotlib (gráficas) Laboratorio 2.3: Pandas (bases de datos)	—	Spanos** (caps. bayesianos)
4	8-Sep	-Big data, IA y Economía	Laboratorio 3: Econometría frecuentista y máxima verosimilitud Laboratorio 4: Análisis bayesiano	PC1	Lectura complementaria (se publicará en Canvas si aplica)

N°	Fecha	Temas (teoría)	Laboratorio (práctica)	Evaluación asociada	Lectura sugerida
5	15-Sep	-Aprendizaje no supervisado: Análisis de Componentes Principales (PCA)	Laboratorio 5: PCA	—	ISLR* cap. 12
6	22-Sep	-Aprendizaje no supervisado: Agrupación (*Clustering*) -Aprendizaje supervisado: Vecinos más cercanos (*k-nearest neighbors*)	Laboratorio 6: Clustering & k-nearest neighbors	—	ISLR* cap. 12, cap. 4
—	—	EXAMEN PARCIAL	—	fecha fijada por Secretaría Académica	—
7	13-Oct	-Regresor James-Stein -Regresión paso a paso hacia adelante (*Forward Stepwise Regression*)	Laboratorio 7: Regresor James-Stein y Sparse Modeling	—	Efron & Hastie*** cap. 7
8	20-Oct	-Ridge -Lasso	Laboratorio 8: Ridge & Lasso	—	ISLR* cap. 6
9	27-Oct	-Logit -Árboles de regresión (*Regression Trees*)	Laboratorio 9: Logit & Regression Trees	Publicación del TCG1	ISLR* cap. 4, cap. 8
10	3-Nov	-Jackknife -Bootstrap	Laboratorio 10: Jackknife & Bootstrap	Semana de entrega del TCG1 Publicación del TCG1	Efron & Hastie*** cap. 10–11; ISLR* cap. 5
11	10-Nov	-Validación cruzada (*Cross Validation*) -*Random forest*	Laboratorio 11: Cross Validation y Random Forest	—	ISLR* cap. 5, cap. 8
12	17-Nov	-Poda de bosques aleatorios (*Pruning*) -*Boosting* y *bagging*	Laboratorio 12: *Pruning*, *Boosting* & *Bagging*	Semana de entrega del TCG2	ISLR* cap. 8
—	—	SEMANA DE FINALES	—	Exposiciones del TCG2: fecha fijada por Secretaría Académica	—

** ISLR = James, Witten, Hastie & Tibshirani (2013), An Introduction to Statistical Learning. ** Spanos = Spanos (2019), Probability Theory and Statistical Inference. *** Efron & Hastie = Efron & Hastie (2021), Computer Age Statistical Inference.*

EVALUACIÓN

Tabla resumen de pesos

N°	Descripción	Tipo evaluación	Peso	Anulable	Fecha
1	Práctica calificada 1	Práctica	15%	No	Semana del 7 de setiembre
2	Examen parcial	Examen	20%	No	Fijada por Secretaría Académica
3	Trabajo calificado grupal 1	Trabajo	20%	No	Semana del 2 de noviembre
4	Trabajo calificado grupal 2	Trabajo	30%	No	Entrega: semana del 23-Nov / Exposición: semana de finales
5	Controles grupales de conocimiento	Controles	15%	1 anulable	Aleatorias, sin aviso previo
	Total		**100%**		
	Punto extra por asistencia perfecta (no acumulable más allá de 20)				

Detalle por rubro

1. Práctica calificada 1 (15 %)

- Contenido: sílabo y 3 primeras semanas de clase (algoritmos y aprendizaje estadístico, filosofías econométricas, análisis bayesiano).
- Estructura: ejercicios matemáticos breves + preguntas abiertas y de Verdadero-Falso-Incierto.
- **Criterios de evaluación:** corrección matemática/estadística de los ejercicios y claridad de argumentación en las preguntas abiertas.
- Solución y entrega: enteramente virtual, se resuelve en casa a mano y en papel; se escanea/fotografía y se entrega vía Canvas. Se requiere tener la cámara encendida durante toda la evaluación.
- Fecha tentativa: semana del 7 de setiembre. Duración tentativa: 2.0 horas. No anulable.

2. Examen parcial (20 %)

- Contenido: sílabo y 6 primeras semanas de clase, acumulativo (incluye temas de la PC1, *big data*/IA/Economía, PCA, *clustering* y KNN).
- Estructura y entrega: similar a la PC1 (enteramente virtual, resolución en papel, escaneo y entrega vía Canvas, cámara encendida).
- Fecha: determinada por la Secretaría Académica de CC. EE. EE. (semana de parciales). Duración tentativa: 2.25 horas (135 minutos).

3. Trabajo calificado grupal[4] 1 (20 %)

- Contenido: 6 primeras semanas de clase. Estructura: casi enteramente de codificación.
- Criterios de evaluación sugeridos: correcto funcionamiento del código, buenas prácticas (comentarios y nombres de variables claros), interpretación económica de los resultados y reproducibilidad del notebook.
- Solución y entrega: resolución en casa y entrega de un único archivo .ipynb (Jupyter Notebook) vía Canvas.
- Fecha tentativa de entrega: semana del 02 de noviembre. Duración tentativa: 7 días. No anulable.

4. Trabajo calificado grupal 2 (30 %)

- Contenido: semana 7 a semana 12. Estructura: casi enteramente de codificación.

[4] Los grupos ya han sido formados (de manera pseudo-aleatoria) y están en Canvas como grupos_E2TEE9_2026_II.pdf.

- Entrega 1 (20 %): archivo .ipynb vía Canvas, resolución en casa.
- Por escrito: qué parte resolvió cada persona.
- Entrega 2 / exposición (10 %): durante las dos horas de examen final se realiza una exposición grupal vía Zoom sobre la resolución de algún ejercicio del trabajo. Vestimenta formal.
- Se escoge al azar a una persona para responder una pregunta en la que NO trabajó; si no responde o responde mal, se aplica un descuento de 5 puntos sobre esta nota grupal (la del 10 %), y luego cualquier integrante del grupo puede responder. La nota es grupal, sin importar quién conteste.
- Fecha tentativa de entrega: semana del 23 de noviembre. Fecha de exposiciones: determinada por Secretaría Académica (semana de finales). No anulable.

5. Controles grupales de conocimiento (15 %)

- Cuatro controles grupales en dos formatos: mini-Kahoot! y preguntas abiertas, detallados en la Guía: Controles Calificados Grupales.
- Fechas asignadas de manera aleatoria y sin aviso previo. Uno de estos controles se puede anular.
- En cada clase hay posibilidad de ganar puntos extra para esta nota respondiendo preguntas en formato Kahoot! (no necesariamente con esa aplicación).
- Revisar la Guía: Controles Calificados Grupales, publicada en Canvas.

No hay examen final escrito ni examen sustitutorio en este curso.

POLÍTICAS DEL CURSO

Política	Regla
Entregas tardías (trabajos)	Descuento de 5 puntos (-5) por atraso sobre la nota obtenida. Si el plazo vence a las 11:59 p.m. (hora de Piura, UTC−5), entregar después se considera atraso. Por cada día adicional de atraso se descuentan 5 puntos más (día 2: -10, etc.).
Entregas tardías (PC1)	Hasta 3 minutos después de la hora acordada: descuento de 5 puntos (-5). Después de 3 minutos: no se recibe.
Entregas tardías (EP)	Hasta 1 minuto después de la hora acordada: descuento de 5 puntos (-5). Después de 1 minuto: no se recibe.
Política de "curva"	No habrá curva en ninguna circunstancia.
Examen sustitutorio	No hay examen sustitutorio.
Examen final	No hay examen final escrito; ese espacio se usa para las exposiciones grupales.
Anulabilidad	Ningún rubro es anulable, salvo un (1) control grupal de conocimiento.
Asistencia	Se toma lista visualmente en cualquier momento después de 10 minutos de iniciada la clase; ingresar después de 20 minutos se considera falta. Las inasistencias no necesitan ser justificadas y no se justificarán en ninguna circunstancia.
Punto extra por asistencia	Un punto extra en el promedio final por asistencia perfecta (no acumulable más allá de 20): detallado en la Guía: puntos de bono y puntos extra, publicada en Canvas.
Puntos de bono y puntos extra	Los tipos de puntos adicionales, cómo se ganan y los topes por evaluación están detallados en la Guía: puntos de bono y puntos extra, publicada en Canvas.

Reclamos	El procedimiento, los canales y los plazos para reclamar una nota están detallados en la Guía: cómo presentar un reclamo de nota, publicada en Canvas.
Cámaras y micrófonos	Cámara encendida durante las sesiones virtuales (para efectos de asistencia). Micrófonos apagados salvo al pedir la palabra; se pide levantar la mano por Zoom para intervenir.
Celulares	Se pide evitar el uso de celulares en clase. En caso de una llamada urgente, verificar que el micrófono (no la cámara) esté apagado, y colocar el teléfono en modo No Interrumpir.
Alimentos y bebidas	Está permitido comer bocadillos e hidratarse con bebidas (no alcohólicas) durante la clase.

COMUNICACIÓN Y ATENCIÓN A ALUMNOS

Para resolver dudas fuera de clase, escribir al correo martin.vargas.a@udep.edu.pe con copia a mavargasalvines@vt.edu siguiendo estas indicaciones:

- Describir claramente la duda y especificar en qué sesión y qué diapositiva/laboratorio se encuentra. De ser posible, adjuntar una captura de pantalla de la diapositiva en cuestión.
- El asunto del correo debe tener el siguiente formato exacto: **"E2TEE9 – Dudas - Sesión X, slide xx / laboratorio xx"** (de lo contrario, el correo puede llegar a la carpeta de "No deseados" y no ser visto).
- Se recomienda presentarse en cada correo, por ejemplo: "Hola, soy [Nombre Apellido], alumno/alumna del curso E2TEE9, escribo porque tengo la siguiente duda: ...".

Horario de atención (oficina) previo aviso: viernes de 3:00 p.m. a 4:00 p.m. (hora de Piura, UTC−5), de manera virtual.

RECOMENDACIONES PARA EL ESTUDIANTE UDEP

- Durante la primera parte del curso (antes de los parciales) se sugiere repasar la clase de la semana anterior antes de la siguiente sesión, para una mejor consolidación del aprendizaje.
- Se recomienda comentar y anotar el código que se publique: comentarios propios que expliquen cada parte como si fueran para alguien que no sabe nada del tema, usando palabras clave que ayuden a recordarlo.
- En la medida de lo posible, correr los códigos bloque por bloque en casa, asegurándose de entender para qué se escribió cada comando y qué es lo que hace.

INTEGRIDAD ACADÉMICA

Las evaluaciones individuales (práctica calificada y examen parcial) son estrictamente individuales: no se permite consultar la solución con compañeros ni compartir respuestas, ni durante ni después de la evaluación mientras algún estudiante siga rindiéndola.

Los trabajos grupales son colaborativos dentro del grupo. Compartir código, resultados o interpretaciones entre grupos distintos constituye una falta, tanto para quien copia como para quien facilita el material.

Copiar código o texto de terceros (repositorios, foros, trabajos de ciclos anteriores) sin citar la fuente constituye plagio. Adaptar código público está permitido y es parte del oficio, siempre que se indique de dónde salió y se entienda lo que hace.

Cualquier falta a lo anterior se sanciona con la nota mínima en esa evaluación (cero), sin perjuicio del procedimiento disciplinario que corresponda según el reglamento de la Universidad.

USO DE IA GENERATIVA

Aunque el uso de herramientas de inteligencia artificial, incluidas ChatGPT, Grok, DeepSeek, Claude, Gemini y otras tecnologías de investigación o escritura impulsadas por IA, puede resultar tentador, es importante considerar sus implicaciones éticas.

En este curso, las herramientas de IA generativa solo podrán utilizarse en tareas específicas designadas por el profesor del curso. Si la actividad requiere el uso de IA, se indicará en sus instrucciones. Para todas las demás evaluaciones (práctica, trabajos y exámenes), el uso de herramientas de IA está prohibido y constituye una falta académica que debe ser reportada como tal. Cuando se requiera/permita el uso de IA, los estudiantes deben comunicar cómo fue utilizada la IA mediante las citas apropiadas. Si en algún momento tiene dudas sobre el uso de IA, es su responsabilidad consultar con el profesor antes de proceder.

Si reconozco indicios de uso no autorizado de IA, se citará al estudiante a una breve entrevista oral (que quedará grabada) sobre su propio examen/práctica/trabajo. La calificación de esa evaluación se determinará por la capacidad de explicar el razonamiento presentado.

ADICIONALES

De manera voluntaria y anónima, se pedirá a los estudiantes que completen encuestas cortas después de cada clase para brindar retroalimentación sobre el desempeño del profesor.

Se planea que algunos exalumnos del Programa Académico de Economía compartan un espacio de 15 minutos para conversar sobre sus experiencias en el campo laboral, con el fin de mostrar cómo es ejercer la Economía en distintas ramas de la profesión.

BIBLIOGRAFÍA

Bibliografía base

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning (Vol. 112). New York: Springer.
- Spanos, A. (2019). Probability Theory and Statistical Inference: Empirical Modeling with Observational Data. Cambridge University Press.
- Efron, B., & Hastie, T. (2021). Computer Age Statistical Inference, Student Edition: Algorithms, Evidence, and Data Science (Vol. 6). Cambridge University Press.

Bibliografía avanzada

- Sargent, T., & Stachurski, J. (2015). Quantitative Economics with Python. Technical report, Lecture Notes.
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. Journal of Economic Perspectives, 31(2), 87–106.
- Athey, S., & Imbens, G. W. (2019). Machine Learning Methods That Economists Should Know About. Annual Review of Economics, 11, 685–725.

Recursos en línea (documentación de librerías de Python)

- NumPy — numpy.org/doc
- pandas — pandas.pydata.org/docs
- Matplotlib — matplotlib.org/stable/index.html
- scikit-learn — scikit-learn.org/stable/user_guide.html

« Solo se aprende bien lo que se aprende con gusto. »
— Anónimo